




Automated Mineral Species Classification of Drill Cores for Efficient Resource Exploration

자원탐사 효율화를 위한 시추 코어 광물 종 자동 분류

Jisung Jung, Hyoengoh Son, Yejin Noh, Jiwoo Choi,
Jaewon Kim, Quwon Lee, Younggyun Kim

Kangwon National University


Global Mineral Demand



The Role of Drill Core Analysis

차세대 자원탐사 기술 : 시추 코어 분석 기술의 역할

- ✓ 지표 하부의 실체적 시료를 직접 제공, 탐사 데이터 정확도 검증의 증거
- ✓ 지층의 퇴적 구조와 암상 경계를 파괴하지 않고 원형 그대로 보존하여 제공
- ✓ 지질학적 변수들 간의 상관관계를 정밀하게 규명하는 통합 분석의 기초 자료
- ✓ 광물 자원의 매장량 산출과 지하 공간의 안정성 평가를 위한 정량적 데이터 제공



Integrating Visual & Geochemical Data

Portable XRF analyzer mineral exploration field



Drill core Images




MSCL (Multi-Sensor Core Logger)




광물 종 자동 분류 단계적 모델 제안

- ✓ 수동 분석의 주관성 및 낮은 효율성 극복
- ✓ 단일 지표 기반 유사 암상 변별의 한계 보완
- ✓ 성분·이미지 결합형 단계적 예측 모델 구축
- ✓ 가용 데이터 기반 물성 추정 및 분석 자동화



DataBase




- Source: IODP Site U1424
- Multi-modal Composition
- 2mm Grid Resolution
- Geophysical Targets
- IMA-based Taxonomy
- HDF5 Data Architecture
- Large-scale Sequence
- Dataset Partitioning & Validation Strategy

Preprocessing

<Core Loss & Data Gaps>




<Linear Interpolation>



Data Preprocessing


- ✓ Step 1: Spatial Alignment via Linear Interpolation
- ✓ Step 2: 1:1 Matching of Visual and Numerical Data
- ✓ Step 3: Missing Value Filtering for Data Integrity
- ✓ Step 4: Min-Max Normalization for Feature Scaling
- ✓ Step 5: Mineral Labeling and HDF5 Data Integration

Automated Mineral Species Classification Model



Input Data -> Property Prediction -> Mineral Classification -> Final Prediction


ResNet-18 & MLP



물리적 특성 예측 모델

- ✓ 지화학 성분 기반 MLP 모델에 시각 정보를 결합하여 지층 환경 변동성을 반영함
- ✓ 과적합 방지를 위해 경량화된 ResNet-18 모델로 코어 이미지의 시각 특징 추출
- ✓ 성분 분석값에 시각적 보정치를 더해 최종적인 물성 3종의 값을 정밀하게 산출함
- ✓ 수식 기반의 하이브리드 구조로 성분과 시각 정보의 유기적 결합을 최적화함
- ✓ 가중치 계수를 통해 학습 과정에서 시각 정보의 기여도를 스스로 조절하도록 설계

XGBoost



광물 종 분류 모델

- ✓ 1단계 예측 물성값과 시각 특징을 통합해 분류 정확도를 극대화한 XGBoost 모델 채택
- ✓ 가중치 부여를 통해 클래스 불균형을 해소하고 희귀 광물 종에 대한 식별력을 강화함
- ✓ 데이터 간 비선형적 상관관계를 학습하여 정형 데이터 분석에서 높은 일반화 성능을 확보
- ✓ Random Search 기법으로 최적 하이퍼파라미터를 산출하여 모델의 예측 신뢰도를 향상
- ✓ 디지털 지질 지도를 즉각 구축할 수 있는 주관성 배제형 데이터 통합 분석 프로세스 제공

Quantitative Performance & Geological Reasoning


<표 3> ResNet-MLP 물성 예측 성능 평가

Value	R ²	MAE	RMSE
P-wave Vel.	0.85	0.03	0.06
Density	0.64	0.05	0.08
Mag. Suscep.	0.79	0.08	0.12

<표 4> XGBoost 분류 성능 평가

Class	Precision	Recall	F1
Melanterite	0.85	0.89	0.87
Schwertmannite	0.96	0.89	0.92
Stornesite-(Y)	0.67	1.00	0.80
Vermiculite	0.82	0.66	0.73
Vivianite	0.68	0.70	0.69
Total Accuracy		0.83	

Stornesite-(Y)




Vivianite



- P-wave 및 자화율에 대해 높은 물성 모사 신뢰도 입증
 - 최신 지물리 데이터 활용 연구 수준의 결정계수를 기록하며 모델 성능 확인
 - 밀도는 복합적 지질 요인의 영향으로 상대적 낮은 상관성 기록
-
- 전체 정확도 83%, 광물 종의 정밀 식별 및 자동화 가능성 확인
 - 뚜렷한 색채 대비와 화학 조성을 가진 광물 군 높은 분류 성능
 - 미세 균열 내 산출되는 광물 특성상 격자 내 특징 혼합이 오분류의 주 원인
 - 무색 광물의 경우 시각적 변별력 한계 극복을 위한 추가 데이터 확충 필요

Grad-CAM & SHAP Value Analysis



Pred: Melanterite


Target: Melanterite
Confidence: Low (47.5%)

► Supporting Evidence

- XRF 11
- XRF 14
- Mag. Sus.

▷ Contradictory Evidence

- XRF 8



Pred: Vermiculite

Target: Vermiculite
Confidence: Low (25.7%)

► Supporting Evidence


- XRF 4
- XRF 18
- P-wave Vel.

▷ Contradictory Evidence

- XRF 11


- ✓ ResNet-18의 합성곱 층에 Grad-CAM을 적용하여 모델이 주목한 시각적 특징을 시각화함
- ✓ XGBoost의 소프트 확률 기반 신뢰도와 SHAP 값을 산출하여 분류의 판단 근거를 명확화함
- ✓ 분류 결과와 함께 긍정·부정적 근거 정보를 동시 제공하여 사용자의 비판적 수용을 지원함
- ✓ 블랙박스 모델의 한계를 극복하고 예측 신뢰성을 확보하여 전문가의 의사결정 분석 기반 마련

Feature Importance



- ✓ 1단계 예측 물성값과 XRF, 시각 특징이 최종 분류에 유기적으로 기여함을 확인
- ✓ 다중 지표의 통합적 해석이 광종 식별의 핵심 변별력임을 정량적으로 입증함
- ✓ 단일 데이터 중심의 기존 한계를 극복하고 이질적 데이터 간 결합 신뢰도 확보
- ✓ 물리·화학적 정보와 시각 패턴의 상호보완적 역할을 통해 분류 정밀도 극대화

Conclusion



- ✓ 시각·지화학·물성 지표를 통합한 하이브리드 자동 분류 모델 제안
- ✓ 기존 육안 분석의 주관적 한계를 극복하고 데이터 기반 객관성 확보
- ✓ 물성 예측 R^2 0.85 및 광물 분류 정확도 83%를 달성하여 성능 입증
- ✓ SHAP 및 Grad-CAM을 통해 모델의 판단 근거를 시각적으로 제시
- ✓ 다중 지표 기반 시추 코어 분석의 국내 기술 표준 및 방법론 정립
- ✓ 향후 데이터 확충을 통해 지역적 범용성 한계와 희귀 광종 분류 보완
- ✓ 스마트 마이닝의 디지털 전환과 국가 자원 수급 안정화 기여를 기대함

References

- ✓ [1] IEA, The Role of Critical Minerals in Clean Energy Transitions (2021).
- ✓ [2] M. Damaschke et al., Geol. Soc. Lond. Spec. Publ., 527, 1-20 (2023).
- ✓ [3] F. Alzubaidi et al., J. Pet. Sci. Eng., 197, 107933 (2021).
- ✓ [4] C. Günther et al., Ore Geol. Rev., 187, 106974 (2025).
- ✓ [5] I. C. Contreras Acosta et al., IEEE JSTARS, 12(12), 4823-4836 (2019).
- ✓ [6] P. Blum, ODP Tech. Note, 26, 1-44 (1997).
- ✓ [7] R. Tada et al., Proc. IODP, 346, 1-105 (2015).
- ✓ [8] I. W. Croudace & R. G. Rothwell (Eds.), Micro-XRF Studies (Springer, 2015).
- ✓ [9] K. He et al., Proc. IEEE CVPR, 770-778 (2016).
- ✓ [10] T. Chen & C. Guestrin, Proc. ACM KDD, 785-794 (2016).
- ✓ [11] J. L. Davalos-Monteiro et al., IPTC, 7-9 (2026).
- ✓ [12] S. Lundberg & S. Lee, Proc. NIPS, 4765-4774 (2017).

Thank you

Annual Conference of KIPS 2026